

MySQL as a Service: LXC Applicationcontainer

Erkan Yanar

INFRASTRUCTURE DESIGN
OF
ARCHITECTURE & STANDARDS

6. März 2012

Agenda

Es geht um Virtualisierung!

- ① MySQL as a Service *mit MySQL Bordmitteln*
- ② Linux: Cgroups & LXC
- ③ MySQL as a Service *mit LXC Applikationscontainer*
- ④ Cgroups demystified
- ⑤ Application as a Service *mit LXC Applikationscontainer*

Einleitung

Die Welt von Alles-as-a-Service:

Am Beispiel von MySQL wird eine SaaS/RDBaaS/DBoD Lösung vorgestellt.

Die bekannteste MySQL SaaS/RDBaaS/DBoD Lösung ist wohl Amazon RDS.

Einleitung

Die Welt von Alles-as-a-Service:

Am Beispiel von MySQL wird eine SaaS/RDBaaS/DBoD Lösung vorgestellt.

Die bekannteste MySQL SaaS/RDBaaS/DBoD Lösung ist wohl Amazon RDS.

Wofür?

Einleitung

Die Welt von Alles-as-a-Service:

Am Beispiel von MySQL wird eine SaaS/RDBaaS/DBoD Lösung vorgestellt.

Die bekannteste MySQL SaaS/RDBaaS/DBoD Lösung ist wohl Amazon RDS.

- Testumgebung
- Upgrades
- Prototyping
- Betrieb

Einleitung

Die Welt von Alles-as-a-Service:

Am Beispiel von MySQL wird eine SaaS/RDBaaS/DBoD Lösung vorgestellt.

Die bekannteste MySQL SaaS/RDBaaS/DBoD Lösung ist wohl Amazon RDS.

- Testumgebung
- Upgrades
- Prototyping
- Betrieb?

Einleitung

Agenda *Erkan Yanar*

- ① RDBaaS mit MySQL Bordmitteln
- ② Rettungsanker Virtualisierung?
- ③ RDBaaS (DBoD) mit LXC Applikationscontainer

Multi-Schema

Aufgabe:

Alle Datenbanken der Projekte werden von einer Instanz bedient

Multi-Schema

Aufgabe:

Alle Datenbanken der Projekte werden von einer Instanz bedient

Neuer Kunde:

```
CREATE SCHEMA schema ;  
GRANT ALL ON schema.* TO kunde@host IDENTIFIED BY password ;
```

Übersicht

| | MULTI SCHEMA |
|---------------------------------------|--------------|
| Easy of Use | X |
| Ressourcenzuweisung zwischen Schemata | - |
| Applikationssp. Conf | - |
| Verschiedene MySQL-Version | - |
| Sep. PITR, Upgrade | - |
| Serverauslastung | - |

Multi Instance

- Verwaltung separater Instanzen
- mysqld_multi
- Sep. User pro Instanz
- Sep. Port pro Instanz

my.cnf

```
[mysqld_multi]
mysqld = /some/mysqld_safe
mysqladmin = /some/mysqladmin
user = multi_admin
password = multipass
[mysqld2]
socket = /tmp/mysql.sock2
port = 3307
pid-file = /some/host.pid2
datadir = /some/var2
user = john
[mysqld3]
socket = /tmp/mysql.sock3
port = 3308
pid-file = /some/host.pid3
```

...

Übersicht

| | MULTI SCHEMA | MULTI INSTANZ |
|---------------------------------------|--------------|---------------|
| Easy of Use | X | - |
| Ressourcenzuweisung zwischen Schemata | - | X |
| Systemressourcen zwischen Instanzen | (-) | - |
| Applikationssp. Conf | - | X |
| Verschiedene MySQL-Version | - | (X) |
| Sep. PITR, Upgrade | - | X |
| Default Port | X | - |
| Serverauslastung | - | X |
| Overhead vieler Instanzen | - | X |

Agent Virtualisierung

Wobei kann Virtualisierung helfen?!

Zumindest bei:

- Ressourcenzuweisung
- Isolation
- Port
- ...

Übersicht

| | MULTI SCHEMA | MULTI INSTANZ | VIRTUALISIERT |
|---------------------------------------|--------------|---------------|---------------|
| Easy of Use | X | - | (X) |
| Ressourcenzuweisung zwischen Schemata | - | X | X |
| Systemressourcen zwischen Instanzen | (-) | - | X |
| Applikationssp. Conf | - | X | X |
| Versch. MySQL-Ver. | - | (X) | X |
| Sep. PITR, Upgrade | - | X | X |
| Default Port | X | - | X |
| Serverauslastung | - | X | X |
| Instanzen Overhead | - | X | X |
| Accounting | - | - | X |

Container aka OS-Virtualisierung und die Anderenunter Linux

Möglichkeiten:




LXC




Linux

Linux kernel diagram



© 2007-2009 Constantine Shulyupin <http://www.MakeLinux.net/kernel/diagram>


KVM etc.



© 2007-2009 Constantine Shulyupin <http://www.MakeLinux.net/kernel/diagram>




Container




© 2007-2009 Constantine Shulvupin <http://www.MakeLinux.net/kernel/diagram>



Two Worlds



© 2007-2009 Constantine Shulyupin <http://www.MakeLinux.net/kernel/diagram>



© 2007-2009 Constantine Shulyupin <http://www.MakeLinux.net/kernel/diagram>

Hardware Virtualisierung kann mehr!

Separates OS

Separater Kernel

Andere Hardwarearchitekturen

Server Auslastung

Hardware Virt.

KVM, Xen, VMWare

X

X

qemu

-

Betriebssystem Virt.

LXC, OpenVZ

-


-

-

X

Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler




Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler




Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- **Hostkernel übernimmt die Verwaltung**
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler




Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler



Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- **Dünne Virtualisierungsschicht**
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler




Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- **Prozessvirtualisierung**
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler




Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- **Prozessvirtualisierung**
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler



Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- **Dynamische Zuweisung von Ressourcen**
- CPU und I/O Scheduler



Container sind:

- Virtualisierung im OS
- Container / Verzeichnisse
- Hostkernel übernimmt die Verwaltung
- → Nur ein OS-Typ
- Dünne Virtualisierungsschicht
- Prozessvirtualisierung
- Dynamische Zuweisung von Ressourcen
- CPU und I/O Scheduler



Überblick

Look@Container ala LXC

Überblick

Look@Container ala LXC

- ① cgroups: Ressourcenmanagement
- ② LXC: (Applikations)Container on top
- ③ OpenVZ vs. LXC kurzer Überblick


Ressourcenmanagement mit cgroups

Control Groups

- Gruppieren von Prozessen
- Gemeinsame Ressourcen
- Childs bleiben in der Gruppe

Control Groups

- VFS
- \geq Kernel 2.6.24
- unabhängig von LXC
- mount:
`cgroup /cgroups cgroup
defaults 0 0`



Subsysteme/Controlgroups

```
cat /proc/cgroups
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1
devices 5 4 1
freezer 6 4 1
net_cls 7 1 1
blkio 8 4 1
```

CPU

Subsysteme/Controlgroups

```
cat /proc/cgroups
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1                                     Speicher
devices 5 4 1
freezer 6 4 1
net_cls 7 1 1
blkio 8 4 1
```

Subsysteme/Controlgroups

```
cat /proc/cgroups
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1
devices 5 4 1                                mknod
freezer 6 4 1
net_cls 7 1 1
blkio 8 4 1
```

Subsysteme/Controlgroups

```
cat /proc/cgroups
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1
devices 5 4 1
freezer 6 4 1 FROZEN/THAWED
net_cls 7 1 1
blkio 8 4 1
```

Subsysteme/Controlgroups

```
cat /proc/cgroups
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1
devices 5 4 1
freezer 6 4 1
net_cls 7 1 1
blkio 8 4 1
```

Markieren

Subsysteme/Controlgroups

```
cat /proc/cgroups
```

```
#subsys_name hierarchy num_cgroups enabled
cpuset 1 4 1
cpu 2 4 1
cpuacct 3 4 1
memory 4 4 1
devices 5 4 1
freezer 6 4 1
net_cls 7 1 1
blkio 8 4 1
```

CFQ

WOHL FÜR DEN TECHTALK WEGNEHMEN

```
# ls /cgroups #2.6.38 (Auszug) --- To be deleted --
blkio.throttle.read_bps_device cpuset.memory_pressure
blkio.throttle.read_iops_device cpuset.memory_pressure_enabled
blkio.throttle.write_bps_device cpuset.mems
blkio.throttle.write_iops_device cpuset.sched_load_balance
blkio.weight cpuset.sched_relax_domain_level
cgroup.clone_children cpu.shares
cgroup.procs devices.allow
cpuacct.stat memory.limit_in_bytes
cpuacct.usage memory.memsw.limit_in_bytes
cpuacct.usage_percpu memory.oom_control
cpuset.cpu_exclusive memory.stat
cpuset.cpus memory.swappiness
cpuset.mem_exclusive memory.usage_in_bytes
cpuset.mem_hardwall net_cls.classid
cpuset.memory_migrate tasks
```

LXC

LXC LinuXContainer

LXC LinuXContainer

Ein chroot macht auf virtuell

LXC LinuXContainer

Grundprinzipien und Stolpersteine

LinuXContainer

LXC: better cgroups?

- Spätestens seit 2.6.26 im Kernel (Network-Namespace)
- Erzeugt mit Hilfe von Namespaces Container.
- cgroups dienen zur Resourcenverwaltung.
- LXC übernimmt die Verwaltung der Prozessgruppen
- Modulares Design!

Namespaces

Die Seele der Virtualisierung

| | | |
|---------|--------------------|---------------|
| utsname | hostname | [Modular] |
| Pid | private PIDs | [Automatisch] |
| User | private UIDs | [Automatisch] |
| Network | privates Interface | [Modular] |
| IPC | privates IPC | [Automatisch] |

LXC virtualisiert chroot() Umgebungen

Konfiguration

/var/lib/lxc/\$CONTAINER Konfigurationsverzeichnis des Containers

/var/lib/lxc/\$CONTAINER/config Konfigurationsdatei des Containers

Wo ist das chroot Verzeichnis?

(lxc.)rootfs Filesystem des Containers

LXC startet dieses „System“

LXC-Tools

Auszug

`lxc-create` Erstellt einen Container

`lxc-destroy` Löscht rootfs und das Configverzeichnis

LXC-Tools

Auszug

`lxc-create` Erstellt einen Container

`lxc-destroy` Löscht rootfs und das Configverzeichnis

Unnötiges Commando?

`lxc-create -n name [-f config_file] [-t template]`

- Schreibe mit config_file nach /var/lib/lxc/\$name/config
- Nutze Template (Skript) zum Erstellen eines Containers
- Mehr zu Templates? Probleme?

Container Filesystem

Erstelle einen Container:

- debootstrap, febootstrap ..
- udevd ausschalten
Daher für i.e. tty, null, zero etc. mknod nutzen
- hwclock entfernen
- ..

lxc-debian

```
/usr/sbin/update-rc.d -f checkroot.sh remove
/usr/sbin/update-rc.d -f umountfs remove
/usr/sbin/update-rc.d -f hwclock.sh remove
/usr/sbin/update-rc.d -f hwclockfirst.sh remove
/usr/sbin/update-rc.d -f module-init-tools remove
```

/usr/lib/lxc/templates

Container Filesystem

Erstelle einen Container:

- debootstrap, febootstrap ..
- udevd ausschalten
Daher für i.e. tty, null, zero etc. mknod nutzen
- hwclock entfernen
- ..

lxc-debian

```
/usr/sbin/update-rc.d -f checkroot.sh remove
/usr/sbin/update-rc.d -f umountfs remove
/usr/sbin/update-rc.d -f hwclock.sh remove
/usr/sbin/update-rc.d -f hwclockfirst.sh remove
/usr/sbin/update-rc.d -f module-init-tools remove
```

/usr/lib/lxc/templates

Container zeigen



Man erstelle eine Konfigurationsdatei

Konfiguration

`lxc.rootfs chroot`

`lxc.mount.entry` Ein Mountpunkt im fstab-Format

`lxc.mount` Pfad zu einem File mit Mountp. im fstab Format

`lxc.tty` Virtuelle Consolen: lxc-console

`lxc.pts` Pseudo ttys

`lxc.cap.drop` man capabilities

```
lxc.tty = 4
lxc.rootfs = /lxc/debian/rootfs
lxc.mount = /lxc/debian/fstab
```

Network

`lxc.network.type`

Kein Eintrag Interfaceeinstellungen
des Hosts

`empty` loopback

`veth` Virtual Ethernet
(bridge)

`macvlan` MAC-Address based
Vlan

`phys` physisches Interface

```
lxc.network.type = veth
lxc.network.flags= up
lxc.network.link = br0
lxc.network.ipv4 =
192.168.1.69/24
lxc.network.name = eth0
lxc.network.veth.pair =
this-veth
```

```
/var/lib/lxc/$CONTAINER/config
```

```
lxc.utsname = zeig
lxc.tty = 4
lxc.pts = 1024

#Vom Host gemounted
lxc.mount = /lxc/debian/fstab

#rootfs
lxc.rootfs = /lxc/debian/rootfs

#Netzwerk:
lxc.network.type = veth
lxc.network.flags = up
lxc.network.link = br0
lxc.network.hwaddr = 08:00:12:34:56:78
lxc.network.ipv4 = 192.168.1.69/24
lxc.network.name = eth0
```

```
...
```

LXC-Tools

Auszug:

`lxc-ls` Zeigt alle konfigurierten und laufenden Container

`lxc-start/stop` Starten/Stoppen eines Containers

`lxc-ps` Wrapper um ps mit Containername

`lxc-console` Konsolenverbindung zum Container

`lxc-execute` Startet einen Prozess im ContainerEnvironment

LXC-Tools

Auszug:

`lxc-ls` Zeigt alle konfigurierten und laufenden Container

`lxc-start/stop` Starten/Stoppen eines Containers

`lxc-ps` Wrapper um ps mit Containernamen

`lxc-console` Konsolenverbindung zum Container

`lxc-execute` Startet einen Prozess im ContainerEnvironment

Applikationscontainer

Show me that stuff!

- Container start
- Host Zugriff
- Privater Prozessspace
- Applikationskontainer mit Ressourcemanagement

Security

Capabilities

remind the fstab

lxc.cap.drop

root im Container zu mächtig

- module sys_module
- mount sys_admin

echo b > /proc/sysrq-trigger

- SELinux
- Smack

lxc.mount.entry=proc \$lxc.rootfs/proc proc nodev,noexec,nosuid,ro 0 0

Applikationscontainer

lxc-execute

- Schlüssel zum Applikationscontainer
- braucht *kein* lxc.rootfs
- Config kann mehrmals verwendet werden (*--name* , *-f*)
- Modularität Ausnutzen

OpenVZ vs. LXC

| Topic | LXC | OpenVZ |
|--------------------------|-----|--------|
| Kernelintegration | X | - |
| Livemigration | - | X |
| Host Konfigtools (vzctl) | - | X |
| Sicheres Netz (venet) | - | X |
| Sichere Container | - | X |
| Applikationscontainer | X | - |
| diskspace | - | X |
| Cgroups | X | - |
| Quota | - | X |
| Distro-Support | X | - |
| Produktionsreif | (-) | X |
| libvirt-Integration | X | (X) |
| Modular | X | - |

DBoD mit LXC

DBoD mit LXC

Grundidee

- Out of the Box-Technik
- Zukunftstechnologie
- Keine Verschwendung von Rechnerressourcen
- Keine weiteren Lizenzkosten

Applikationscontainer mit lxc-execute

lxc-execute


- Schlüssel zum Applikationscontainer
- braucht *kein* lxc.rootfs
- Config kann mehrmals verwendet werden (*--name* , *-f*)
- Modularität Ausnutzen

Realisierung

- lxc-execute
- LVM

Für alle veränderlichen Daten

 - datadir
 - tmpdir
 - Errorlog
 - Application specific Config
- Multi-Package Auswahl an MySQL-Versionen
- Schema dbod Datenbankmanagement



```
lxc.utsname = dbod_8012
#lxc.tty = 1

# Bind-Mounts
lxc.mount.entry =
/opt/app/dbod/mysql//5.5.13/conf/medium /opt/app/mysql/conf none bind 0 0

lxc.mount.entry =
/opt/app/dbod/mysql//5.5.13/pkg/ /opt/app/mysql/product/mysql none bind 0 0

lxc.mount.entry = /data/dbod/dbod_8012 /data none bind 0 0

# Ressourcen
lxc.cgroup.cpu.shares = 2046
lxc.cgroup.memory.limit_in_bytes = 1G
lxc.cgroup.memory.memsw.limit_in_bytes = 1G
```

Tools

- dbod_mysql_create.pl
- dbod_mysql_list.pl
- dbod_mysql_start.pl
- dbod_mysql_stop.pl
- dbod_mysql_upgrade.pl

```
# dbod_mysql_create.pl --port 6005 --number 6005 --mysqlversion 5.5.20
          -t small  --gb 5 --database kunde
OptionCheck is not finished!!!
Logical volume "dbod_6005" created
password for admin on dbod_6005 is yuzPgTRZ92k/U
#
```

```
# dbod_mysql_start.pl -n 6005 && dbod_mysql_list.pl
```

| Instance | MySQL | Port | Status | Memory | cur. | Mem | max |
|-----------|--------------|------|---------|---------|--------|-----|-----|
| dbod_5101 | 5.1.58 | 5101 | ----- | - | - | - | - |
| dbod_5102 | 5.1.58 | 5102 | ----- | - | - | - | - |
| dbod_5103 | 5.1.58 | 5103 | ----- | - | - | - | - |
| dbod_5104 | 5.1.58 | 5104 | ----- | - | - | - | - |
| dbod_5301 | Maria-5.3.0 | 5301 | RUNNING | 524288 | 156032 | | |
| dbod_5305 | Maria-5.3.0 | 5305 | ----- | - | - | - | - |
| dbod_5501 | 5.5.13 | 5501 | RUNNING | 1048576 | 462996 | | |
| dbod_5503 | 5.5.13 | 5503 | ----- | - | - | - | - |
| dbod_6000 | 5.5.20 | 6000 | ----- | - | - | - | - |
| dbod_6001 | 5.5.20 | 6001 | ----- | - | - | - | - |
| dbod_6002 | 5.5.20 | 6002 | ----- | - | - | - | - |
| dbod_6003 | 5.5.20 | 6003 | ----- | - | - | - | - |
| dbod_6004 | 5.5.20 | 6004 | ----- | - | - | - | - |
| dbod_6005 | 5.5.20 | 6005 | RUNNING | 524288 | 461668 | | |
| dbod_8000 | Spider5.5.14 | 8000 | ----- | - | - | - | - |
| dbod_8001 | Spider5.5.14 | 8001 | RUNNING | 1048576 | 468008 | | |
| dbod_8010 | 5.5.13 | 8010 | RUNNING | 1048576 | 77184 | | |
| dbod_8011 | 5.5.13 | 8011 | RUNNING | 1048576 | 464136 | | |
| dbod_8012 | 5.5.13 | 8011 | ----- | - | - | - | - |
| dbod_8020 | 5.5.13 | 8020 | RUNNING | 1048576 | 467200 | | |



Upcoming

- Schema dbod erweitern
- Replication
- Eigene IP
- HA
- Migration
- Btrfs
- Monitoring
- Integration in unsere Automatisierungsumgebung
- Integration in OpenStack/libvirt

Ende Gelände



Erkan Yanar @
INFRASTRUCTURE DESIGN
OF
ARCHITECTURE & STANDARDS
...
linsenraum.de/erkules
www.xing.com/profile/Erkan_Yanar